

Recherche, Formation & Innovation en PAYS de la LOIRE

# Al-based assistant for molecular QUantum chemistry

### Le consortium





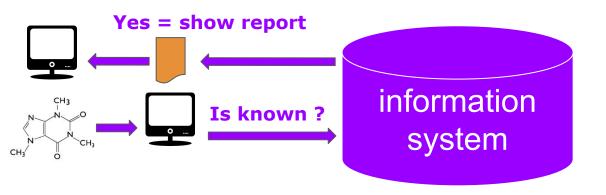
- Benoit DA MOTA
- Gilles HUNAULT
- Béatrice DUVAL
- David LESAINT

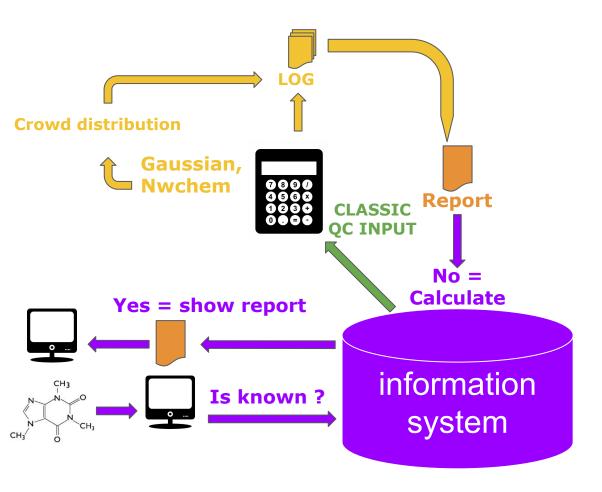
Optimisation combinatoire Big Data Intelligence artificielle Apprentissage artificiel

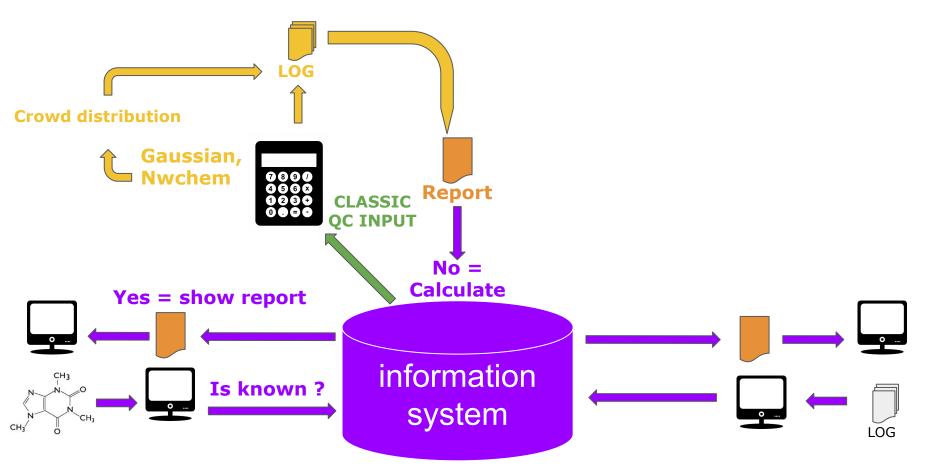
Science des données

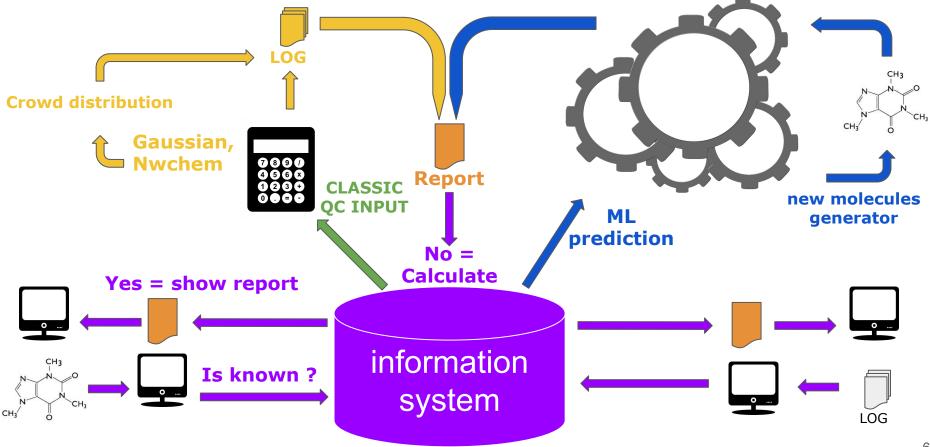
Programmation par contraintes

- Thomas CAUCHY = Chimie théorique
- Yohann MORILLE = Calcul scientifique
- Collègues expérimentateurs

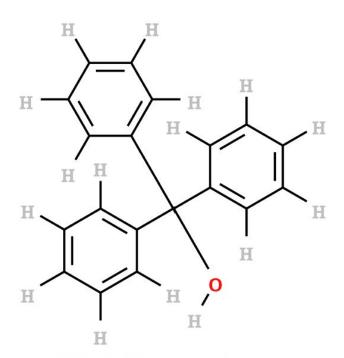




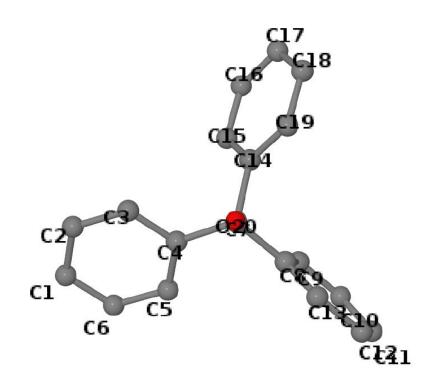




### L'objet : molécule

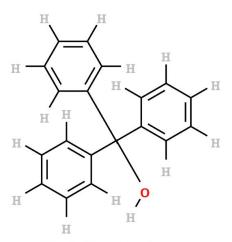


Chemical structure diagram



Géométrie 3D

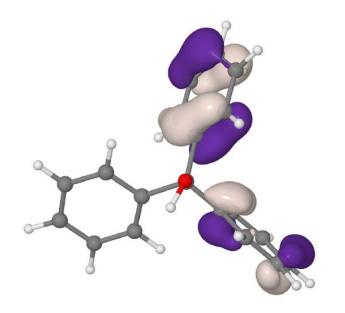
### L'objet : molécule



Chemical structure diagram

Most intense Mulliken atomic charges mean = -0.000 e, std = 0.186

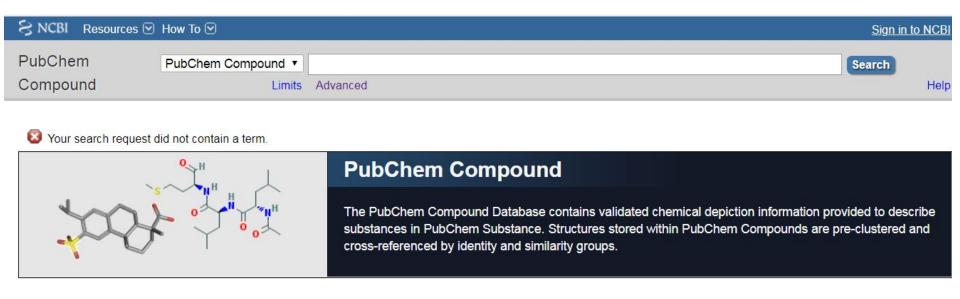
Atom	number	Mulliken charges	
O	20	-0.647	
$\mathbf{C}$	5	-0.192	
$\mathbf{H}$	36	0.394	



Représentation d'une isosurface décrivant 1 électron (cubes de voxels)

### Les bases de données disponibles





Base de données expérimentale avec > 100 millions de composés.

### Les bases de données disponibles

### PubChemQC Project: A Large-Scale First-Principles Electronic Structure Database for Data-Driven Chemistry

Maho Nakata\*† n and Tomomi Shimazaki‡ n

- <sup>†</sup> Advanced Center for Computing and Communication, RIKEN, 2-1 Hirosawa, Wako, Saitama 351-0198 Japan
- <sup>‡</sup> Advanced Institute for Computational Science, RIKEN, 7-1-26 Minatojima-minami-machi, Chuo-ku, Kobe, Hyogo 650-0047 Japan

J. Chem. Inf. Model., 2017, 57 (6), pp 1300-1308

**DOI:** 10.1021/acs.jcim.7b00083

Publication Date (Web): May 8, 2017

Copyright © 2017 American Chemical Society

\*E-mail: maho@riken.jp.



Base de données théorique avec 3.5 millions de composés. Un seul niveau de théorie. Pas d'apprentissage automatique!

### Les bases de données disponibles

ioChem-BD Browse - Barcelona Supercomputing Center // BSC host

### PubChemDFT Collection home page



This is a **live** project. It uses spare computer time to compute, process, store, and publish open-access DFT results of molecules contained in the PubChem database. For each entry, we provide its optimized geometry, energies, charges, vibrational frequencies, cube files for electron density and electrostatic potential, etc ... Average rate is close to 1000 molecs/day. Started in April 2017, in July 2017 70000 molecules have been completed.

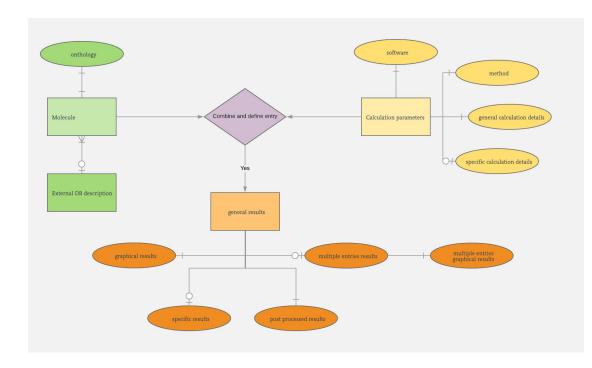
Our Twitter bot @MolecuBot, born July 2017, tweets each time a new molecule is completed and published.



Base de données théorique avec 200 k composés. Un seul niveau de théorie différent de PubChemQC. Pas d'apprentissage automatique!

### L'objet dans notre système d'information

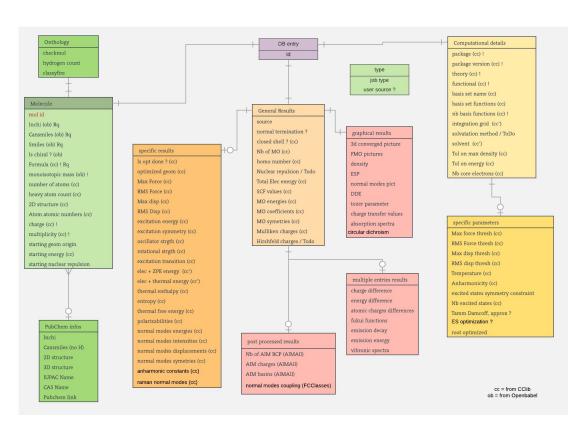
- objectif 100 millions de molécules
- Plusieurs paramètres de calculs
- choix des informations à sauver



### L'objet dans notre système d'information

- objectif 100 millions de molécules
- Plusieurs paramètres de calculs
- choix des informations à sauver

- Calculs Gaussian
  - 500 Mo / molécule
  - de 10 à 1000 h / molécule
- Objectifs:
  - o 10 Mo / molécule
  - soit 1 Po pour les 100 millions



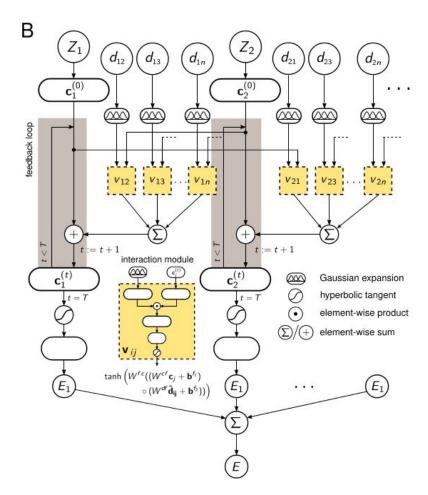
# Projet AIQU

Objectif 1 : Prédire les propriétés chimique

### Travaux existants

[Schütt et al.] Quantum-Chemical Insights from Deep Tensor Neural Networks. *Nature Communications 2017*.

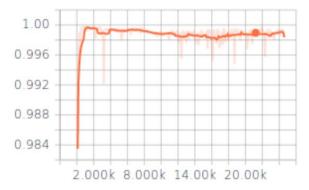
- GDB-9 dataset :
  - combinatoire de l'espace moléculaire pour
    9 atomes lourds parmi C, N, O et F
  - ~134k petites molécules "théoriques"
- Données en entrée pas très homogènes
- RNN très structuré avec de nombreux a priori
- Matrice des distances (D) insensible aux translations et rotations.
  - Problématique de passage à l'échelle
- Prédiction uniquement de l'énergie



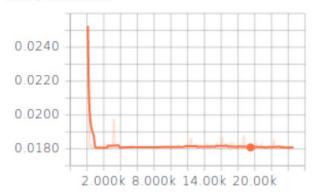
### Travaux préliminaires : Nicolas Roux (M1)

- PubChemQC dataset
  - > 3 millions de molécules "réelles"
  - échantillon de l'espace moléculaire général
- Données homogènes (DFT, B3LYP, 6-31G\*)
- NN simple (3 couches entièrement connectées)
- Prévu pour le passage à l'échelle
  - Matrice <u>partielle</u> des distances: insensible aux translations et rotations.
- Prédit les distances pour l'état fondamental à partir de distances "bruitées".

#### accuracy\_ns/Validation



#### Loss/Validation

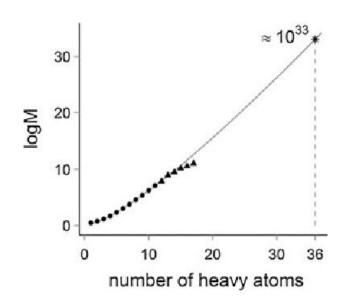


# Projet AIQU

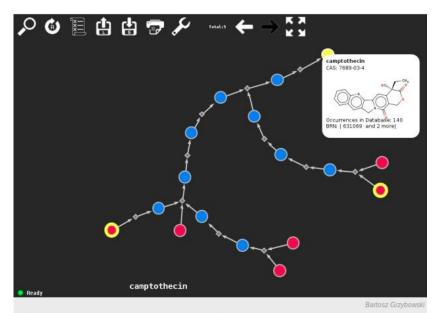
Objectif 2 : Parcourir l'espace moléculaire

### Fonctions d'évaluation + relations de voisinage = algorithmes de recherche locale

- Fonctions d'évaluation
  - Prédire les propriétés chimiques
  - Prédire le coût de synthèse
- Relations de voisinage
  - Produire des molécules proches, pouvant exister et stables
- Comparaison avec les techniques génératives issues de l'apprentissage profond



### Evaluer le coût de synthèse ?



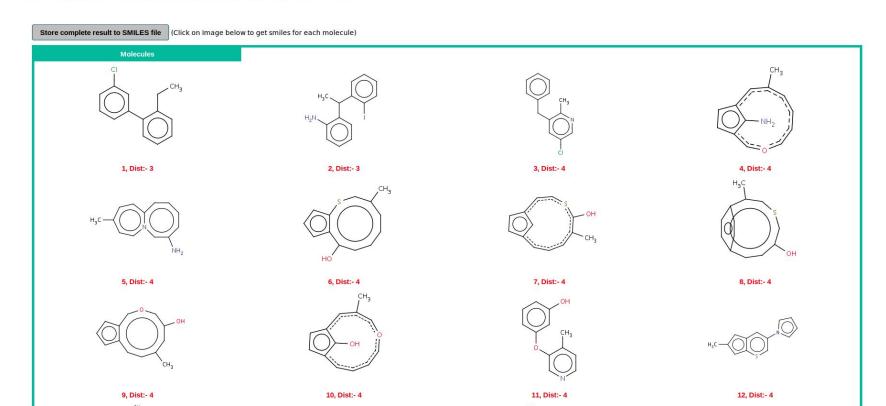
Chematica is a program that looks for synthetic pathways leading from starter chemicals (red), through sequences of intermediates (blue), to a target compound (yellow). The target in this example is camptothecin: a naturally occurring compound that is the basis of several cancer drugs.

- La rétrosynthèse (1) planifie l'ensemble des réactions permettant la synthèse d'une cible à partir d'un catalogue de composés
  - Informatif pour le chimistes
  - Chiffrage précis du nombre de réactions
  - Difficile d'associer un coût
  - Coûteux en temps de calcul
- Solutions envisagées :
  - Apprentissage (2): Prédiction rapide mais imparfaite du coût de synthèse Bowen L. et al. Retrosynthetic reaction prediction using neural sequence-to-sequence models. CoRR 2017.
  - Programmation par contraintes (3)
  - (1) + (3) pour entraîner (2)

### Parcourir le voisinage des molécules stables ?

#### Search done!

Retrieved 1000 neighbors of c2ccc(Cc1cccc1)cc2 from GDB-17 using 1.096 seconds server time.



## Conclusion

### Jalons du projet, post-doc et valorisation

M1 : Modèles prédictifs de la géométrie

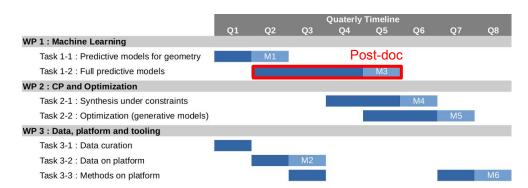
M2 : Données publiques sur la plateforme

M3 : Modèles prédictifs d'un calcul en chimie quantique

**M4** : Modélisation des contraintes et du coût de synthèse

M5 : Modèles génératifs

**M6**: Outils méthodologiques et techniques sur plateforme



#### Stratégie de valorisation :

- 1. Une plateforme publique internationale
- 2. Des publications en chimie et en informatique
- 3. Des modèles prédictifs libres et utilisables
- 4. Un projet voué à s'ouvrir à des partenaires extérieurs

### Quantum chemistry

POSTULATE I. For any possible state of a system, there is a function,  $\Psi$ , of the coordinates of the parts of the system and time that completely describes the system.  $\Psi = \Psi(x, y, z, t)$ .

The quantity  $\Psi^*\Psi d\tau$  is proportional to the probability of finding the particles of the system in the volume element,  $d\tau = dx dy dz$ . We require that the total probability be unity (1) so that the particle must be *somewhere*. That is,

$$\int_{\text{all space}} \Psi^* \Psi \, d\tau = 1. \tag{2.6}$$

If this condition is met, then  $\Psi$  is *normalized*. In addition,  $\Psi$  must be *finite*, single valued, and continuous. These conditions describe a "well-behaved" wave function. The reasons for these requirements are as follows:

### Quantum chemistry

POSTULATE IV. The state function,  $\Psi$ , is given as a solution of

$$\hat{H}\Psi = E\Psi, \tag{2.38}$$

where  $\hat{H}$  is the operator for total energy, the *Hamiltonian operator*.

$$\hat{H} = \hat{T} + \hat{V},\tag{2.39}$$

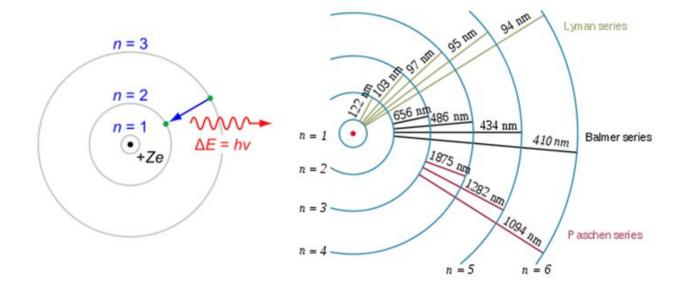
where  $\hat{T}$  is the operator for kinetic energy and  $\hat{V}$  is the operator for potential energy.

### Quantum model of atoms

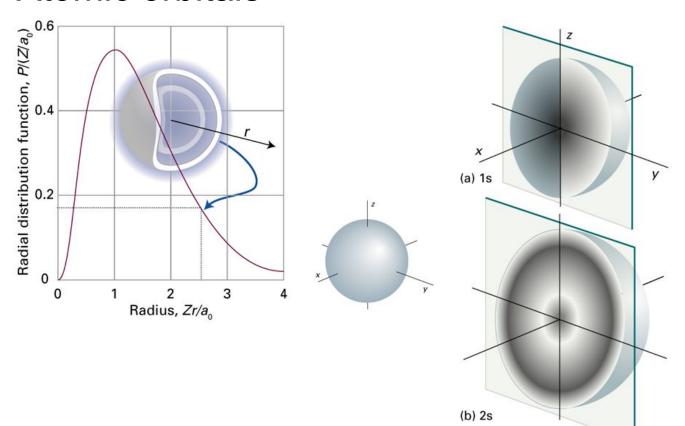


© The Nobel Foundation

Niels Bohr 1885-1962 Université de Copenhague, Danemark



### Atomic orbitals



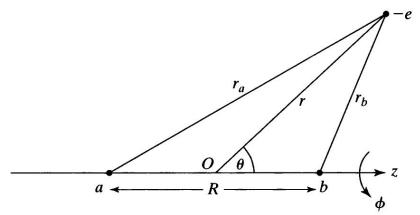


FIGURE 13.3 Interparticle distances in H<sub>2</sub><sup>+</sup>.

$$\begin{split} \hat{T} &= -\sum_{i}^{N} \frac{\hbar^{2}}{2m_{e}} \nabla_{i}^{2} - \sum_{k}^{M} \frac{\hbar^{2}}{2m_{k}} \nabla_{k}^{2} \\ V &= -\sum_{i}^{N} \sum_{k}^{M} \frac{Z_{k}e^{2}}{4\pi\epsilon_{0}r_{ik}} + \sum_{i}^{N} \sum_{j>i}^{N} \frac{e^{2}}{4\pi\epsilon_{0}r_{ij}} + \sum_{k}^{M} \sum_{l>k}^{M} \frac{Z_{k}Z_{l}e^{2}}{4\pi\epsilon_{0}R_{kl}} \end{split}$$

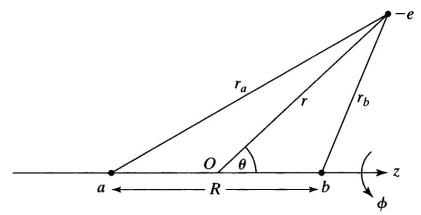
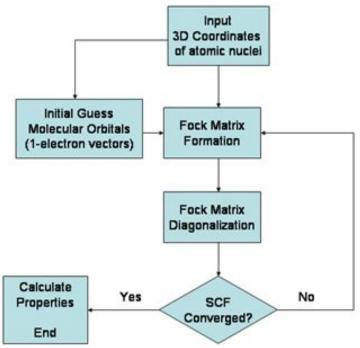


FIGURE 13.3 Interparticle distances in H<sub>2</sub><sup>+</sup>.

$$\begin{split} \hat{T} &= -\sum_{i}^{N} \frac{\hbar^2}{2m_e} \nabla_i^2 - \sum_{k}^{M} \frac{\hbar^2}{2m_k} \nabla_k^2 \\ V &= -\sum_{i}^{N} \sum_{k}^{M} \frac{Z_k e^2}{4\pi\epsilon_0 r_{ik}} + \left(\sum_{i}^{N} \sum_{j>i}^{N} \frac{e^2}{4\pi\epsilon_0 r_{ij}}\right) + \sum_{k}^{M} \sum_{l>k}^{M} \frac{Z_k Z_l e^2}{4\pi\epsilon_0 R_l} + \sum_{k}^{M} \sum_{l>k}^{$$



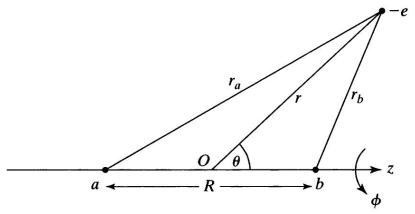
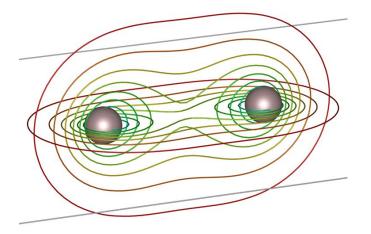
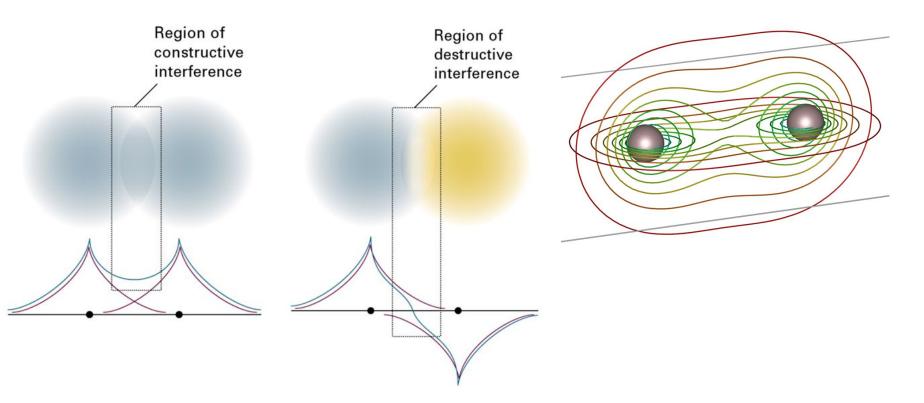
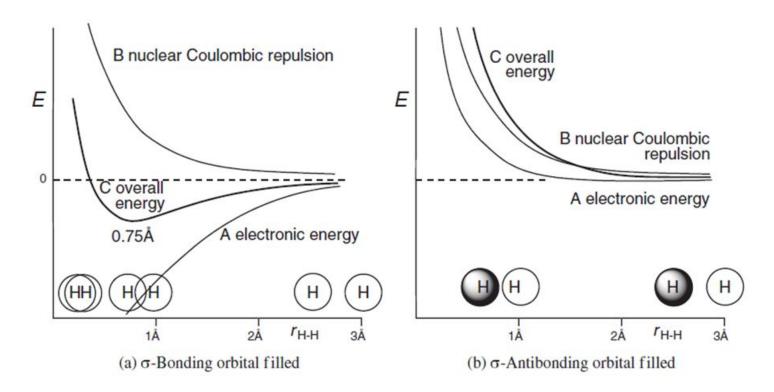


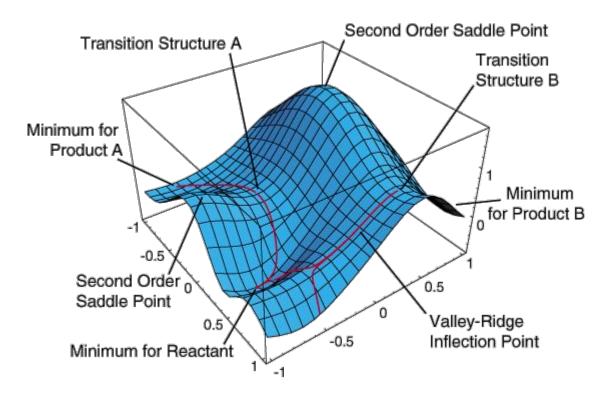
FIGURE 13.3 Interparticle distances in  $H_2^+$ .



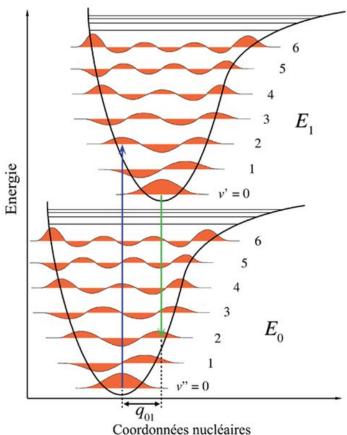


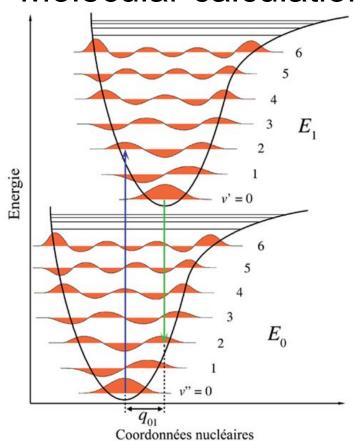


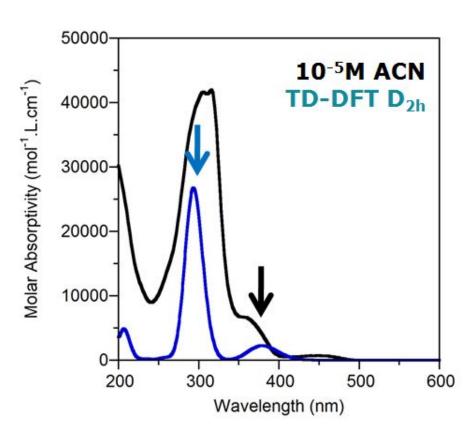
### Molecular calculations: after SCF, OPT



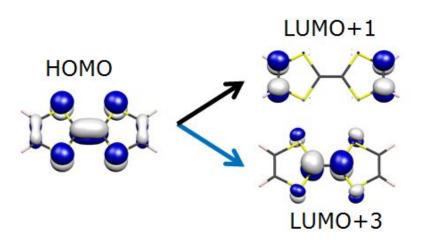
### Molecular calculations: after OPT, freq puis TD

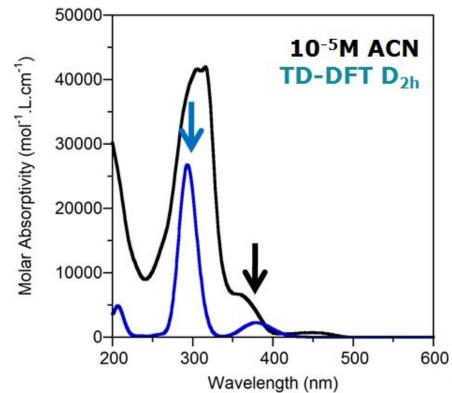




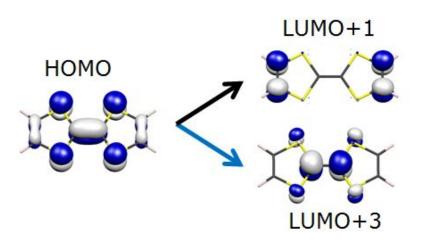


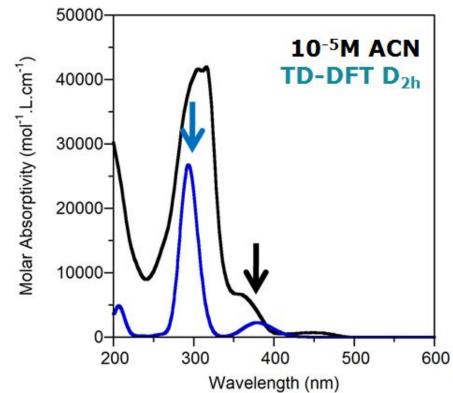
λ(nm)	f.	transition
379	0.03	HO → LU+1 (99%)
293	0.37	HO → LU+3 (99%)

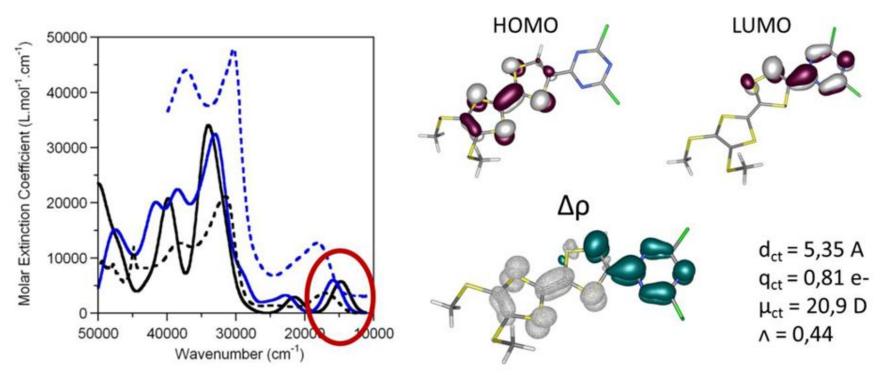




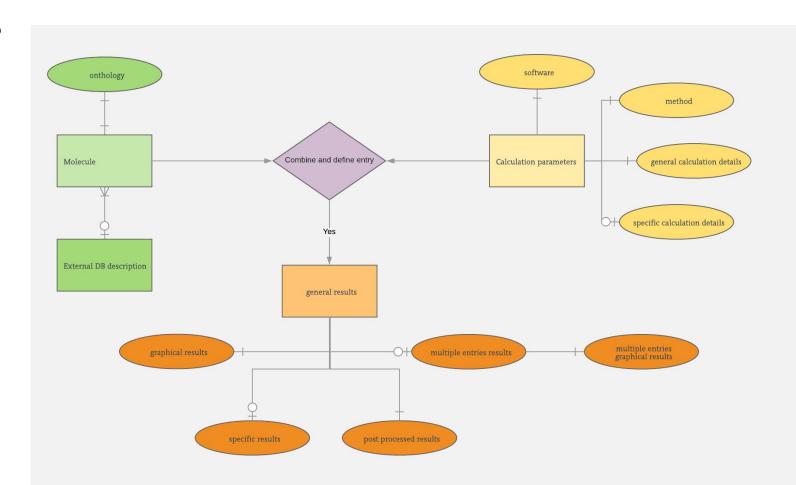
λ(nm)	f.	transition
379	0.03	HO → LU+1 (99%)
293	0.37	$HO \rightarrow LU+3 (99\%)$







### Results



### Results

